

Medicinska robotika 2025./2026.

Teme seminarskih radova

Poštovane kolegice i kolege,

u sklopu kolegija Medicinska robotika svaki student odabire jednu od ponuđenih seminarskih tema. Cilj seminarskog rada nije samo pregled odabranog područja, već razvoj tehničkog razumijevanja, sposobnosti analize problema, implementacije metoda te kritičke evaluacije rezultata u kontekstu medicinske robotike.

Teme su podijeljene prema razini složenosti, pri čemu pojedina razina određuje maksimalnu ocjenu koju je moguće ostvariti:

- Osnovna razina – maksimalna ocjena: dobar (3)
- Srednja razina – maksimalna ocjena: vrlo dobar (4)
- Napredna razina – maksimalna ocjena: odličan (5)

Odabir više razine podrazumijeva veći opseg rada, višu razinu samostalnosti, detaljniju eksperimentalnu evaluaciju i dublju tehničku analizu.

Seminarski radovi mogu uključivati:

- modeliranje i simulaciju robotskih sustava
- razvoj i implementaciju algoritama
- obradu senzorskih podataka
- eksperimentalni rad na stvarnim sustavima
- analizu podataka i validaciju rezultata
- tehničku usporedbu postojećih metoda i rješenja

Naglasak kolegija stavljen je na inženjerski pristup rješavanju problema, a ne isključivo na opisivanje postojećih tehnologija. U svakom radu očekuje se vlastiti doprinos kroz implementaciju, eksperimentalnu evaluaciju, tehničku analizu ili kritičku raspravu.

Korištenje AI alata

Korištenje AI alata (npr. ChatGPT, Claude, Copilot i slični alati) dopušteno je kao pomoć pri:

- pretraživanju literature
- strukturiranju rada
- programiranju i razvoju prototipnih rješenja
- analizi alternativnih pristupa

Međutim, AI alati ne mogu zamijeniti razumijevanje problema i samostalni inženjerski rad. Student je obavezan jasno navesti jesu li i na koji način AI alati korišteni tijekom izrade rada.

Ocjenjuje se:

- razumijevanje problema
- kvaliteta implementacije ili tehničke analize
- kvaliteta eksperimentalne validacije
- interpretacija rezultata

- sposobnost kritičke rasprave o ograničenjima i mogućim poboljšanjima

Tijekom obrane student mora samostalno objasniti i argumentirati sva tehnička rješenja korištena u radu.

ZAJEDNIČKI OKVIR ZA SVE SEMINARE

Za sve seminarske radove vrijede sljedeći zahtjevi:

- Obavezna implementacija, modeliranje ili originalna tehnička analiza, ovisno o odabranoj temi
- Obavezna evaluacija rezultata
- Obavezan pregled literature, koji uključuje:
 - minimalno 5 znanstvenih radova
 - preporučeno radove ne starije od 5 godina (osim seminalnih radova kada su relevantni)
 - izvore iz relevantnih znanstvenih baza i izdavača (IEEE, Springer, Elsevier, ACM i slično)

Literatura mora biti aktivno korištena, a ne samo formalno citirana:

- u obrazloženju odabira metode ili pristupa
- u usporedbi s vlastitim rezultatima
- u kritičkoj raspravi o ograničenjima i alternativnim rješenjima

STRUKTURA IZVJEŠĆA (ZNANSTVENI RAD)

Svi seminarski radovi predaju se u formi strukturiranog tehničkog / znanstvenog rada.

Maksimalna duljina rada: 12 stranica (bez priloga, ako su potrebni)

Preporučena struktura:

Sažetak (Abstract)

Kratki prikaz:

- problema
- korištenog pristupa
- glavnih rezultata

1. Uvod

- motivacija i kontekst problema
- relevantnost za medicinsku robotiku
- ciljevi rada

Uvod mora sadržavati i:

- Pregled povezanih radova (Related Work)
- pregled relevantne literature
- postojeći pristupi
- identifikacija ograničenja postojećih rješenja

2. Metodologija

Opis tehničkog pristupa:

- arhitektura sustava
- korišteni algoritmi i metode
- matematički model (ako je primjenjivo)
- implementacijski detalji

Primjeri:

- računalni vid
- optimizacija
- strojno učenje
- filtriranje
- planiranje gibanja
- obrada senzorskih podataka
- komunikacijski protokoli (TCP/UDP/RTDE i sl.)
- analiza latencije

3. Eksperimentalni postav (ako rad uključuje fizički robotski sustav)

Opis eksperimentalnog sustava:

- korišteni hardver
- robotski sustav
- senzori
- simulator (ako se koristi)
- korišteni dataset
- ispitanici (ako postoje)

4. Rezultati i analiza

Obavezno uključiti:

- kvantitativne metrike
- grafove
- tablični prikaz rezultata gdje je primjenjivo
- analizu pogrešaka
- robusnost sustava
- latenciju (ako je relevantna)

5. Rasprava (Discussion)

Kritička interpretacija:

- ograničenja razvijenog rješenja
- usporedba s literaturom
- mogući izvori pogreške
- prijedlozi poboljšanja

6. Zaključak i budući rad

- glavni doprinos rada
- sažetak rezultata
- preporuke za nastavak razvoja

Predaja rada

Predaja seminarskog rada sastoji se od:

- pisanog rada (Word ili LaTeX + PDF)
- konačne PowerPoint prezentacije
- izvornog koda / konfiguracijskih datoteka / dodatnih materijala (ako je primjenjivo)

Materijale je potrebno predati putem sustava e-učenje najkasnije dan prije ispitnog roka do ponoći.

Obrana rada

Prezentacije će se održati uživo u CRTA laboratoriju.

Trajanje:

- maksimalno 10 minuta prezentacije
- dodatna tehnička rasprava i pitanja

Kod praktičnih tema može se tražiti:

- demonstracija sustava
- dodatna analiza modificiranog scenarija
- tehnička obrana implementiranog rješenja

Analiza „sposobnosti“ robotskog manipulatora

Tip zadatka: Praktični – uključuje programiranje, validaciju i analizu rezultata

Maksimalni broj odabira: 2

Kontekst i motivacija

Za planiranje složenih robotskih zadataka, osobito u medicinskim i intervencijskim primjenama, ključno je razumjeti geometrijska i kinematska ograničenja robotskog manipulatora. Sama implementacija algoritama za analizu radnog prostora danas je tehnički dostupna, no stvarni izazov leži u interpretaciji dobivenih rezultata, identifikaciji singularnosti i procjeni praktične uporabljivosti robota za konkretni zadatak.

Cilj seminara je razviti, validirati i analizirati metode za procjenu kinematskih sposobnosti robotskog manipulatora te interpretirati rezultate iz perspektive medicinske robotike.

Varijanta A – Osnovna razina / Maksimalna ocjena: dobar (3)

Fokus

Implementacija osnovne analize radnog prostora i kinematskih sposobnosti jednog robotskog manipulatora.

Zahtjevi

1. Implementirati model jednog robotskog manipulatora u odabranom alatu:
 - i. RoboDK
 - ii. Matlab
 - iii. Python
 - iv. drugi alat uz odobrenje mentora
2. Implementirati osnovnu analizu workspacea:
 - dohvatljive pozicije TCP-a
 - osnovna vizualizacija u 3D prostoru
3. Analiza:
 - identificirati osnovna ograničenja sustava
 - interpretirati rezultat za konkretnu robotsku primjenu

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Dodatno:

1. Analiza najmanje dva robotska sustava različite kinematske strukture
2. Usporedba:
 - oblik workspacea
 - dostupne orijentacije
 - utjecaj ograničenja zglobova
3. Analiza singularnosti:
 - identificirati problematične konfiguracije
 - objasniti njihov utjecaj
4. Kriitička rasprava:
 - prednosti i ograničenja različitih robota


Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Dodatno:

1. Implementirati napredniju metriku sposobnosti:
 - primjerice: manipulability, dexterity, capability maps
2. Analiza utjecaja:
 - diskretizacije
 - numeričkih aproksimacija
 - odabira modela
3. Interpretacija iz perspektive medicinske primjene:
 - npr. intervencijska robotika, robotska asistencija, manipulacija u ograničenom prostoru
4. Kritički prijedlog poboljšanja metode

Literatura: F. Zacharias, C. Borst, and G. Hirzinger, "Capturing robot workspace structure: representing robot capabilities," in 2007 IEEE/RSJ International Conference on Intelligent Robots and Systems, San Diego, CA, USA, 2007, pp. 3229–3236.

Kontakt osoba za izradu seminara: Bojan Šekoranja



Model za kalibraciju alata robota– TCP i smjera

Tip zadatka: Praktični – uključuje izradu i eksperiment

Maksimalni broj odabira: 2

Kontekst i motivacija

Točna kalibracija alata robota jedan je od ključnih preduvjeta za precizno izvođenje robotskih zadataka. U medicinskoj i intervencijskoj robotici pogreška u određivanju položaja vrha alata može izravno utjecati na točnost zahvata, sigurnost pacijenta i pouzdanost robotskog sustava. Posebno je važno ne odrediti samo položaj TCP-a, nego i smjer alata, primjerice os igle, sonde, vodilice ili kirurškog instrumenta.

Iako postoje standardne metode kalibracije TCP-a, stvarni izazov leži u njihovoj praktičnoj implementaciji, procjeni točnosti, robusnosti na mjerni šum i razumijevanju ograničenja postupka. U sklopu seminara potrebno je razviti i implementirati model za kalibraciju TCP-a i smjera alata koristeći kinematski model robota te eksperimentalno ili simulacijski prikupljene podatke.

Cilj seminara je razviti, validirati i kritički analizirati algoritam za kalibraciju alata robota te kvantitativno procijeniti utjecaj broja mjerenja, kvalitete podataka i mjernog šuma na točnost procjene. U radu se očekuje kritička analiza mogućih izvora pogreške i prijedlog poboljšanja postupka.

Varijanta A – Osnovna razina / Maksimalna ocjena: dobar (3)

Student implementira osnovni postupak kalibracije TCP-a robotskog alata.

Potrebno je obraditi:

1. Osnovni pojam TCP-a i koordinatnih sustava robota
2. Razliku između koordinatnog sustava baze, prirubnice, alata i TCP-a
3. Kinematski model odabranog robotskog manipulatora
4. Osnovni postupak prikupljanja mjerenja za TCP kalibraciju
5. Implementaciju jedne metode za procjenu TCP-a, primjerice:
 - geometrijski pristup
 - metoda najmanjih kvadrata
 - numerička optimizacija
6. Vizualizaciju dobivenog TCP-a u odnosu na koordinatni sustav robota
7. Osnovnu evaluaciju točnosti na simuliranim ili stvarnim podacima

Potrebno je prikazati rezultate u obliku tablica, grafova ili 3D vizualizacije te objasniti kako pogreška kalibracije može utjecati na preciznost medicinskog robotskog zadatka.

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz sve zahtjeve iz varijante A, potrebno je napraviti usporedbu najmanje dva pristupa određivanju TCP-a.

Potrebno je dodatno obraditi:

1. Usporedbu metoda:
 - geometrijska metoda
 - optimizacijska metoda
2. Kalibraciju smjera alata, primjerice osi igle, sonde ili vodilice
3. Analizu utjecaja broja mjerenja na točnost procjene
4. Analizu utjecaja kvalitete podataka i mjernog šuma
5. Usporedbu rezultata na simuliranim i stvarnim podacima
6. Procjenu robusnosti algoritma
7. Identifikaciju mogućih izvora pogreške, primjerice:
 - pogreška kinematskog modela

- pogreška očitavanja zglobova
- neprecizno ručno pozicioniranje
- deformacija ili savijanje alata
- pogreška referentne točke

Student treba pokazati razumijevanje razlike između formalne implementacije algoritma i njegove praktične uporabljivosti u stvarnom robotskom sustavu.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz sve zahtjeve iz varijanti A i B, potrebno je napraviti napredniju tehničku analizu postupka kalibracije i predložiti poboljšani ili robusniji pristup.

Potrebno je dodatno obraditi:

1. Propagaciju pogreške kroz transformacijski lanac robot – prirubnica – alat – TCP
2. Osjetljivost procjene na:
 - broj konfiguracija
 - raspored orijentacija
 - šum u mjerenjima
 - geometriju alata
 - izbor optimizacijske funkcije
3. Kvantitativnu evaluaciju pogreške:
 - pogreška položaja TCP-a
 - pogreška smjera alata
 - srednja pogreška
 - maksimalna pogreška
 - standardna devijacija
4. Usporedbu rezultata s relevantnim metodama iz literature
5. Prijedlog vlastitog poboljšanja postupka kalibracije
6. Kritičku raspravu o primjenjivosti metode u medicinskoj robotici

Moguće napredne nadogradnje uključuju automatski odabir najboljih konfiguracija za kalibraciju, robusnu optimizaciju, odbacivanje loših mjerenja, Monte Carlo analizu utjecaja šuma ili integraciju vanjskog mjernog sustava poput kamere, OptiTracka ili lokalizacijskog sustava.

Očekivani rezultati rada

Seminar treba sadržavati implementirani algoritam za kalibraciju TCP-a i smjera alata, opis korištenog matematičkog modela, eksperimentalni ili simulacijski postupak prikupljanja podataka, kvantitativnu evaluaciju točnosti i kritičku analizu ograničenja. Očekuje se usporedba najmanje dva pristupa za više razine rada, prikaz rezultata u tabličnom i grafičkom obliku te jasna interpretacija važnosti kalibracije u medicinskim robotskim primjenama.

Literatura:

Peter Corke, Robotics, Vision and Control: Fundamental Algorithms in MATLAB

Kontakt osoba za izradu seminara: Bojan Šekoranja

Kooperativna manipulacija

Tip zadatka: Praktični – uključuje izradu i eksperiment

Maksimalni broj odabira: 2

Kontekst i motivacija

U medicinskoj robotici često je potrebno precizno pozicionirati vrh alata u definiranu ciljanu točku, ali istovremeno omogućiti promjenu orijentacije alata oko te točke. Takvi zahtjevi pojavljuju se u intervencijskoj robotici, biopsiji, neurokirurgiji, robotskom vođenju igle, ultrazvučnom snimanju i drugim postupcima u kojima je važno pristupiti istoj anatomskej lokaciji iz različitih smjerova.

U takvim primjenama korisno je razviti sustav kooperativne manipulacije u kojem operator ručno vodi robota primjenom sile, dok robot ograničava gibanje tako da vrh alata ostaje u ciljanj točki. Time se omogućuje intuitivna interakcija čovjeka i robota, ali uz zadržavanje geometrijskih i sigurnosnih ograničenja.

Cilj seminara je razviti model i program za UR5 ili sličan robotski manipulator koji omogućuje ograničeno gibanje oko ciljane točke, promjenu orijentacije alata uz zadržavanje TCP-a te povratnu silu ili virtualna ograničenja koja vode korisnika tijekom ručnog vođenja.

Varijanta A – Osnovna razina / Maksimalna ocjena: dobar (3)

Student implementira osnovni model gibanja alata oko ciljane točke.

Potrebno je obraditi:

1. Osnovni pojam kooperativne manipulacije i ručnog vođenja robota
2. Koordinatne sustave robota, alata i ciljane točke
3. Model ograničenog gibanja oko fiksne točke
4. Implementaciju osnovne funkcionalnosti:
 - vrh alata ostaje u ciljanj točki
 - orijentacija alata se mijenja oko ciljane točke
 - gibanje se izvodi ručnim vođenjem ili zadavanjem komandi
5. Vizualizaciju ili demonstraciju gibanja
6. Osnovnu provjeru pogreške položaja TCP-a tijekom promjene orijentacije

Za osnovnu razinu dovoljno je implementirati i validirati rotaciju oko ciljane točke u simulaciji ili na stvarnom robotu uz osnovnu analizu točnosti.

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz sve zahtjeve iz varijante A, potrebno je implementirati napredniju funkcionalnost promjene efektivne duljine alata.

Potrebno je dodatno obraditi:

1. Model virtualnog alata promjenjive duljine
2. Funkcionalnost skraćivanja i produljivanja alata uz zadržavanje vrha alata u istoj ciljanj točki
3. Izračun potrebnih translacijskih i rotacijskih pomaka robota
4. Analizu pogreške položaja vrha alata tijekom:
 - promjene orijentacije
 - promjene duljine alata
 - kombiniranog gibanja
5. Eksperimentalnu evaluaciju na UR5 robotu ili u simulacijskom okruženju
6. Usporedbu idealnog geometrijskog modela i stvarnog ponašanja sustava

Student treba prikazati koliko precizno sustav održava ciljanu točku i u kojim konfiguracijama dolazi do najvećih odstupanja.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz sve zahtjeve iz varijanti A i B, potrebno je implementirati ili detaljno analizirati force feedback, virtualna ograničenja ili sigurnosno vođenje korisnika.

Potrebno je dodatno obraditi:

1. Force feedback ili virtual fixture pristup za ograničavanje neželjenog gibanja
2. Model dopuštenog i nedopuštenog gibanja robota
3. Implementaciju sigurnosnih ograničenja:
 - ograničenje pomaka TCP-a
 - ograničenje orijentacije
 - ograničenje sile
 - ograničenje brzine
4. Analizu interakcije čovjeka i robota tijekom ručnog vođenja
5. Kvantitativnu evaluaciju:
 - pogreška položaja TCP-a
 - pogreška orijentacije
 - sila interakcije
 - glatkoća gibanja
 - stabilnost sustava
 - latencija upravljanja, ako je relevantna
6. Kritičku raspravu o primjenjivosti sustava u medicinskim zahvatima

Moguće napredne nadogradnje uključuju admittance control, impedance control, virtual fixtures, ograničenje gibanja u stošcu pristupa, sigurnosne zone, prikaz dopuštenog područja gibanja ili usporedbu različitih načina ručnog vođenja.

Očekivani rezultati rada

Seminar treba sadržavati matematički i programski model kooperativne manipulacije, implementaciju na UR5 robotu ili u odgovarajućem simulatoru, demonstraciju gibanja oko ciljane točke, kvantitativnu analizu pogreške TCP-a i kritičku raspravu o ograničenjima. Za više razine očekuje se implementacija promjenjive duljine alata i force feedbacka ili virtualnih ograničenja za sigurnije vođenje korisnika.

Literatura: UR5 User Manual

Kontakt osoba za izradu seminara: Bojan Šekoranja

Razvoj algoritma za detekciju pokreta u rehabilitaciji

Tip zadatka: Praktični – uključuje izradu i eksperiment

Maksimalni broj odabira: 2

Kontekst i motivacija

Objektivna analiza ljudskog pokreta važan je dio suvremene rehabilitacije. U klasičnom rehabilitacijskom procesu procjena kvalitete izvedbe vježbe često ovisi o subjektivnoj procjeni terapeuta, dok računalni vid omogućuje kvantitativno praćenje položaja tijela, amplituda pokreta, simetrije, brzine i pravilnosti izvedbe.

Sustavi za procjenu položaja tijela, poput MediaPipea, OpenPosea ili drugih metoda za human pose estimation, omogućuju razvoj algoritama koji iz videosnimke mogu izdvojiti ključne točke tijela i analizirati izvedbu rehabilitacijskih vježbi. Takvi sustavi mogu biti temelj za povratnu informaciju korisniku, telerehabilitaciju, objektivno praćenje napretka i integraciju s rehabilitacijskim robotskim sustavima.

Cilj seminara je razviti algoritam za detekciju i analizu rehabilitacijskog pokreta iz videosnimke te evaluirati njegovu sposobnost praćenja, klasifikacije ili ocjene pravilnosti izvedene vježbe.

Varijanta A – Osnovna razina / Maksimalna ocjena: dobar (3)

Student implementira osnovni algoritam za detekciju i praćenje pokreta na temelju videosnimke.

Potrebno je obraditi:

1. Osnovne principe računalnog vida u analizi ljudskog pokreta
2. Pregled metoda za procjenu položaja tijela:
 - MediaPipe
 - OpenPose
 - druge dostupne metode
3. Odabir jedne rehabilitacijske vježbe
4. Prikupljanje vlastite videosnimke i korištenje javno dostupnog primjera
5. Implementaciju algoritma u Pythonu
6. Detekciju ključnih točaka tijela
7. Izračun osnovnih parametara pokreta, primjerice:
 - kut zgloba
 - amplituda pokreta
 - trajanje pokreta
 - broj ponavljanja
8. Osnovnu vizualizaciju rezultata

Za osnovnu razinu potrebno je pokazati da algoritam može detektirati pokret i izdvojiti barem jedan relevantan biomehanički parametar iz videosnimke.

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz sve zahtjeve iz varijante A, potrebno je razviti sustav za procjenu pravilnosti izvedbe vježbe.

Potrebno je dodatno obraditi:

1. Definiciju referentnog ili ispravnog obrasca pokreta
2. Usporedbu izvedenog pokreta s unaprijed definiranim standardom
3. Analizu više videosnimki ili više ponavljanja iste vježbe
4. Detekciju odstupanja, primjerice:
 - premala amplituda pokreta
 - nepravilna putanja
 - asimetrija lijeve i desne strane tijela
 - prebrzo ili presporo izvođenje
 - nepravilno držanje tijela
5. Generiranje osnovne povratne informacije korisniku
6. Evaluaciju algoritma prema odabranim metrikama:
 - točnost detekcije ponavljanja
 - pogreška procjene kuta
 - stabilnost praćenja tijekom vremena
 - broj izgubljenih detekcija
 - usporedba s ručno označenim referentnim vrijednostima

Student treba pokazati da algoritam ne radi samo detekciju položaja tijela, nego i interpretira kvalitetu izvedenog rehabilitacijskog pokreta.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz sve zahtjeve iz varijanti A i B, potrebno je napraviti napredniju analizu robusnosti, usporedbu metoda ili koncept sustava za rehabilitacijsku primjenu.

Potrebno je dodatno obraditi:

1. Usporedbu najmanje dvije metode ili konfiguracije, primjerice:
 - MediaPipe i OpenPose
 - 2D i 3D pose estimation
 - različite kamere ili kutovi snimanja
 - različiti algoritmi filtriranja
2. Analizu robusnosti na:
 - promjenu osvjetljenja
 - promjenu kuta kamere
 - djelomičnu okluziju tijela
 - različite korisnike
 - različitu brzinu izvođenja vježbe
3. Filtriranje i obradu vremenskih signala:
 - izgladivanje kutova
 - detekcija faza pokreta
 - detekcija početka i kraja ponavljanja
4. Moguću primjenu strojnog učenja za:
 - klasifikaciju ispravnog i neispravnog pokreta
 - prepoznavanje vrste vježbe
 - procjenu kvalitete izvedbe
5. Prijedlog arhitekture sustava za rehabilitacijsku primjenu
6. Kritičku raspravu o ograničenjima računalnog vida u stvarnoj rehabilitaciji

Moguće napredne nadogradnje uključuju izradu manjeg vlastitog dataseta, ručno označavanje referentnih pokreta, usporedbu više korisnika, integraciju s grafičkim sučeljem ili izradu prototipa sustava koji daje povratnu informaciju u stvarnom vremenu.

Očekivani rezultati rada

Seminar treba sadržavati implementirani algoritam za detekciju i analizu rehabilitacijskog pokreta, opis korištene metode računalnog vida, videosnimke ili dataset korišten za testiranje, kvantitativnu evaluaciju rezultata i kritičku raspravu o ograničenjima. Očekuje se prikaz ključnih točaka tijela, grafovi promjene kutova ili drugih parametara tijekom vremena, procjena pravilnosti izvedbe te prijedlog poboljšanja sustava za stvarnu rehabilitacijsku primjenu.

Preporučeni alati:

Python, OpenCV, MediaPipe, OpenPose ili slične biblioteke za procjenu položaja tijela.

Kontakt osoba za izradu seminara: Bojan Šekoranja

Upravljački pristupi za autonomno robotsko ultrazvučno snimanje

Tip zadatka: Teorijski seminar s naglaskom na pregled literature, analizu postojećih sustava i kritičku usporedbu upravljačkih pristupa.

Maksimalni broj odabira: 2

Kontekst i motivacija

Robotski potpomognuto ultrazvučno snimanje sve se više istražuje kao način povećanja preciznosti, ponovljivosti i ergonomije dijagnostičkih postupaka. Za razliku od klasičnog ručnog ultrazvučnog pregleda, kod robotskog sustava sonda je pričvršćena na robotsku ruku koja mora ostvariti stabilan kontakt s tijelom pacijenta ili medicinskim fantomom.

Jedan od ključnih izazova je održavanje odgovarajuće kontaktne sile između ultrazvučne sonde i površine snimanja. Premala sila može uzrokovati lošu kvalitetu slike i gubitak kontakta, dok prevelika sila može biti neugodna ili potencijalno nesigurna za pacijenta. Zbog toga autonomno ultrazvučno snimanje zahtijeva kombinaciju upravljanja silom, prilagodljivog gibanja robota, obrade ultrazvučne slike i sigurnosnih mehanizama.

Cilj seminara je istražiti i kritički analizirati upravljačke pristupe koji se koriste u autonomnom robotskom ultrazvučnom snimanju, s posebnim naglaskom na održavanje konstantne kontaktne sile između ultrazvučne sonde i objekta snimanja.

Varijanta A – Osnovna razina / Maksimalna ocjena: dobar (3)

Potrebno je izraditi pregled područja autonomnog robotskog ultrazvučnog snimanja.

Potrebno je obraditi:

1. Osnovne principe ultrazvučnog snimanja u medicini
2. Razliku između ručnog i robotski potpomognutog ultrazvučnog snimanja
3. Osnovne komponente robotskog sustava:
 - a. robotska ruka
 - b. ultrazvučna sonda
 - c. senzor sile/momenta
 - d. sustav za obradu slike
 - e. sigurnosni mehanizmi
4. Problem održavanja kontakta između sonde i površine tijela
5. Osnovni pregled upravljačkih pristupa:
 - a. pozicijsko upravljanje
 - b. upravljanje silom
 - c. impedance control
 - d. admittance control

Potrebno je pronaći i opisati nekoliko relevantnih znanstvenih radova te objasniti zašto je održavanje kontaktne sile važno za kvalitetu ultrazvučne slike i sigurnost pacijenta.

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz sve zahtjeve iz varijante A, student treba napraviti usporednu analizu različitih upravljačkih pristupa.

1. Detaljniju usporedbu:
 - a. force control
 - b. impedance control
 - c. admittance control
 - d. hybrid position/force control
2. Prednosti i ograničenja svakog pristupa u kontekstu ultrazvučnog snimanja
3. Način mjerenja i regulacije kontaktne sile

4. Utjecaj geometrije površine tijela na stabilnost kontakta
5. Ulogu ultrazvučne slike u zatvorenoj petlji upravljanja
6. Pregled najmanje 3 konkretna robotska sustava iz literature

Za svaki odabrani sustav potrebno je prikazati:

1. Korištenog robota
2. Vrstu senzora
3. Tip upravljanja
4. Cilj snimanja
5. Razinu autonomije
6. Ograničenja sustava

Potrebno je pokazati razumijevanje razlike između upravljačkih strategija i povezanost istih s konkretnim medicinskim zahtjevima.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz sve zahtjeve iz varijanti A i B, potrebno je napraviti dubinsku kritičku analizu područja i predložiti mogući koncept autonomnog sustava za robotsko ultrazvučno snimanje.

Potrebno je dodatno obraditi:

1. Napredne pristupe autonomnom ultrazvučnom snimanju:
 - a. Image-guided control
 - b. Learning-based control
 - c. Adaptive force control
 - d. Shared autonomy
 - e. Multimodal control
2. Problem robusnosti sustava:
 - a. Promjene anatomije
 - b. Gibanje pacijenta
 - c. Deformabilnost tkiva
 - d. Šum u mjerenju sile
 - e. Promjena kvalitete ultrazvučne slike
3. Sigurnosne aspekte:
 - a. Ograničenje sile
 - b. Ograničenje brzine robota
 - c. Detekcija gubitka kontakta
 - d. Hitno zaustavljanje
 - e. Interakcija s liječnikom ili operatorom
4. Kriterije evaluacije sustava:
 - a. Stabilnost kontaktne sile
 - b. Kvaliteta ultrazvučne slike
 - c. Pokrivenost područja snimanja
 - d. Vrijeme snimanja
 - e. Sigurnost i udobnost pacijenta
 - f. Razina autonomije
5. Prijedlog vlastite arhitekture sustava

Seminar uz pregled literature treba sadržavati i kritičku sintezu područja te argumentirani prijedlog vlastitog koncepta autonomnog robotskog ultrazvučnog sustava.

Kontakt osoba za izradu seminara: Tara Knežević

Primjena EMG signala u analizi i predikciji ljudskog pokreta za rehabilitacijsku robotiku

Tip zadatka: Teorijski seminar s naglaskom na pregled literature, analizu postojećih metoda i kritičku usporedbu pristupa za interpretaciju i predikciju ljudskog pokreta pomoću EMG signala.

Maksimalni broj odabira: 2

Kontekst i motivacija

Elektromiografija (EMG) koristi se za mjerenje električne aktivnosti mišića te predstavlja jedan od najvažnijih izvora informacija o ljudskom pokretu i namjeri kretanja. U rehabilitacijskoj robotici EMG signali omogućuju razvoj sustava koji mogu prepoznati korisnikovu namjeru, procijeniti aktivaciju pojedinih mišićnih skupina te prilagoditi ponašanje robotskog sustava stvarnom stanju korisnika.

Primjene EMG-a uključuju rehabilitacijske robote, egzoskelete, protetske sustave, fizičku interakciju čovjeka i robota, analizu biomehanike pokreta te sustave za predikciju ljudske namjere. Posljednjih godina posebno se istražuju metode strojnog učenja i multimodalne analize koje kombiniraju EMG s kinematičkim, vizijskim i dinamičkim podacima.

Jedan od glavnih izazova je velika varijabilnost EMG signala između različitih korisnika, osjetljivost na pozicioniranje senzora, prisutnost šuma te potreba za pouzdanom interpretacijom signala u stvarnom vremenu.

Cilj seminara je istražiti i kritički analizirati primjenu EMG signala u analizi i predikciji ljudskog pokreta, s naglaskom na rehabilitacijsku robotiku i sustave fizičke interakcije čovjeka i robota.

Varijanta A – Osnovna razina / Maksimalna ocjena: dobar (3)

Potrebno je izraditi pregled osnovnih principa EMG mjerenja i njihove primjene u analizi ljudskog pokreta.

Potrebno je obraditi:

1. Osnovne principe elektromiografije:
 - a. Površinski EMG
 - b. Intramuskularni EMG
 - c. Osnovne karakteristike signala
2. Fiziološku osnovu mišićne aktivnosti i generiranja EMG signala
3. Osnovne komponente EMG sustava:
 - a. Elektrode
 - b. Pojačala
 - c. Sustavi za akviziciju podataka
4. Pozicioniranje EMG senzora na različite dijelove tijela
5. Utjecaj:
 - a. Položaja elektroda
 - b. Šuma
 - c. Pokreta kože
 - d. Zamora mišića
 - e. Individualnih razlika korisnika
6. Osnovne primjene EMG-a:
 - a. Analiza pokreta
 - b. Rehabilitacija
 - c. Protetika
 - d. Egzoskeleti
 - e. Biomehanika

Potrebno je pronaći i opisati nekoliko relevantnih znanstvenih radova te prikazati nekoliko primjera primjene EMG-a u rehabilitaciji i robotici.

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz sve zahtjeve iz varijante A, potrebno je detaljnije analizirati metode interpretacije i predikcije pokreta pomoću EMG signala.

1. Metode obrade EMG signala:
 - a. Filtriranje
 - b. Normalizacija
 - c. Ekstrakcija značajki
 - d. RMS i frekvencijske karakteristike
2. Metode predikcije pokreta:
 - a. Klasifikacija pokreta
 - b. Procjena zglobnih kutova
 - c. Predikcija sile i momenta
 - d. Prepoznavanje faza pokreta
3. Primjenu strojnog učenja u obradi EMG signala:
 - a. SVM
 - b. Neuronske mreže
 - c. Deep learning pristupi
4. Pregled javno dostupnih EMG datasetova
5. Usporedbu motion science i robotics pristupa
6. Pregled najmanje 3 sustava iz literature koji koriste EMG za:
 - a. Rehabilitaciju
 - b. Egzoskelete
 - c. Protetske sustave
 - d. Fizičku interakciju čovjeka i robota

Za svaki sustav potrebno je prikazati:

1. Korištene senzore
2. Broj EMG kanala
3. Pozicije elektroda
4. Vrstu pokreta
5. Korištene algoritme
6. Glavna ograničenja sustava

Seminar treba pokazati razumijevanje obrade EMG signala i različitih pristupa predikciji ljudskog pokreta.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz sve zahtjeve iz varijanti A i B, potrebno je napraviti dubinsku kritičku analizu suvremenih pristupa EMG-temeljenoj predikciji ljudskog pokreta.

Potrebno je dodatno obraditi:

1. Multimodalne pristupe:
 - f. EMG + motion capture
 - g. EMG + force sensing
 - h. EMG + vision systems
 - i. EMG + inertial sensors
2. Problem generalizacije modela između različitih korisnika
3. Real-time izazove:
 - a. Latencija
 - b. Robusnost

- c. Šum
 - d. Promjene položaja elektroda
 - e. Promjene mišićne aktivnosti tijekom vremena
4. Primjenu EMG-a u:
- a. Rehabilitacijskoj robotici
 - b. Egzoskeletima
 - c. Kolaborativnoj robotici
 - d. Predikciji ljudske namjere
 - e. Adaptivnim upravljačkim sustavima
5. Etičke i sigurnosne izazove
- a. Privatnost biomehaničkih podataka
 - b. Pouzdanost sustava
 - c. Sigurnost pri fizičkoj interakciji
6. Buduće trendove
- a. Foundation modeli
 - b. Wearable AI
 - c. Personalized rehabilitation
 - d. Digital humans
 - e. Human-in-the-loop sustavi

Potrebno je kritički usporediti različite pristupe iz literature i predložiti mogući koncept sustava koji koristi EMG za predikciju ljudskog pokreta u rehabilitacijskoj robotici.

Predloženi sustav treba sadržavati:

- 1. raspored senzora
- 2. tip podataka
- 3. način obrade signala
- 4. mogući algoritam predikcije
- 5. način integracije s robotskim sustavom
- 6. potencijalnu rehabilitacijsku primjenu

Kontakt osoba za izradu seminara: Tara Knežević

Motion capture sustavi za analizu ljudskog pokreta u rehabilitaciji

Tip zadatka: Teorijski seminar s naglaskom na pregled literature, analizu motion capture sustava i kritičku usporedbu pristupa za snimanje i analizu ljudskog pokreta u rehabilitaciji i robotici.

Maksimalni broj odabira: 2

Kontekst i motivacija

Analiza ljudskog pokreta ima važnu ulogu u rehabilitaciji, biomehanici, sportskoj znanosti i rehabilitacijskoj robotici. Razvoj motion capture sustava omogućio je precizno mjerenje položaja, brzina i ubrzanja dijelova ljudskog tijela tijekom izvođenja pokreta. Takvi sustavi danas se koriste za objektivnu procjenu motoričkih sposobnosti, razvoj rehabilitacijskih protokola, validaciju biomehaničkih modela te upravljanje robotskim sustavima.

U istraživačkim i kliničkim okruženjima posebno se koriste optički motion capture sustavi poput OptiTrack i Vicon platformi, koji omogućuju visoku preciznost praćenja pomoću reflektivnih markera i više sinkroniziranih kamera. Paralelno s time razvijaju se i markerless pristupi temeljeni na računalnom vidu i metodama strojnog učenja.

Posljednjih godina motion capture sustavi sve se češće integriraju s virtualnom stvarnošću, rehabilitacijskim robotima, EMG sustavima i algoritmima umjetne inteligencije radi razvoja personaliziranih i interaktivnih rehabilitacijskih sustava.

Cilj seminara je istražiti i kritički analizirati motion capture sustave za analizu ljudskog pokreta, s naglaskom na njihovu primjenu u rehabilitaciji, biomehanici i robotici.

Varijanta A – Osnovna razina / Maksimalna ocjena: dobar (3)

Potrebno je izraditi pregled osnovnih principa motion capture sustava i njihove primjene u analizi ljudskog pokreta.

Potrebno je obraditi:

1. Osnovne principe motion capture sustava:
 - a. Optički sustavi
 - b. Marker-based sustavi
 - c. Markerless sustavi
2. Osnovne komponente sustava:
 - a. Kamere
 - b. Reflektivni markeri
 - c. Kalibracija
 - d. Rekonstrukcija 3D pokreta
3. Osnovne biomehaničke parametre
4. Osnovne primjene motion capture sustava:
 - a. Rehabilitacija
 - b. Analiza hoda
 - c. Biomehanika
 - d. Sportska analiza
 - e. Robotika
5. Osnovni pregled motion capture sustava:
 - a. OptiTrack
 - b. Vicon
 - c. Kinect ili slični markerless sustavi

Potrebno je pronaći i opisati nekoliko relevantnih znanstvenih radova te objasniti zašto je precizno praćenje pokreta važno u rehabilitaciji i robotici.

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz sve zahtjeve iz varijante A, potrebno je detaljnije analizirati postojeće motion capture pristupe i njihove primjene u rehabilitaciji.

1. Usporedbu:
 - a. Marker-based i markerless pristupa
 - b. OptiTrack i Vicon sustava
 - c. Optičkih i IMU-based sustava
2. Problem kalibracije i sinkronizacije sustava
3. Izvore pogrešaka:
 - a. Okluzije markera
 - b. Šum
 - c. Gubitak markera
 - d. Pogreške rekonstrukcije
4. Pregled javno dostupnih motion capture datasetova
5. Primjenu motion capture sustava u:
 - a. Rehabilitaciji
 - b. Rehabilitacijskoj robotici
 - c. Egzoskeletima
 - d. Analizi hoda
 - e. Fizičkoj interakciji čovjeka i robota
6. Pregled najmanje 3 sustava ili istraživačka rada iz literature

Za svaki sustav potrebno je prikazati:

1. Korišteni motion capture sustav
2. Broj kamera ili senzora
3. Vrstu pokreta
4. Način obrade podataka
5. Primjenu
6. Glavna ograničenja sustava

Seminar treba pokazati razumijevanje različitih motion capture pristupa i njihove primjene u rehabilitacijskim i robotskim sustavima.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz sve zahtjeve iz varijanti A i B, potrebno je napraviti dubinsku kritičku analizu suvremenih pristupa analizi ljudskog pokreta.

Potrebno je dodatno obraditi:

1. Integraciju motion capture sustava s:
 - a. Virtualnom stvarnošću (VR)
 - b. Rehabilitacijskim robotima
 - c. EMG sustavima
 - d. AI algoritmima
 - e. Digital human modelima
2. Immersive i VR rehabilitacijska okruženja:
 - a. Motivacija korisnika
 - b. Gamification
 - c. Embodiment
 - d. User engagement
 - e. Cybersickness

3. Multimodalne pristupe:
 - a. Motion capture + EMG
 - b. Motion capture + force sensing
 - c. Motion capture + vision systems
4. Real-time izazove:
 - a. Latencija
 - b. Sinkronizacija podataka
 - c. Obrada velikih količina podataka
 - d. Robustnost sustava
5. Buduće trendove:
 - a. Markerless AI pristupi
 - b. Digital twins
 - c. Foundation modeli za ljudski pokret
 - d. Personalized rehabilitation
 - e. Human motion prediction
6. Kritičku analizu ograničenja motion capture sustava u stvarnim rehabilitacijskim scenarijima

Potrebno je kritički usporediti različite pristupe iz literature i predložiti mogući koncept sustava za analizu ljudskog pokreta u rehabilitaciji ili robotici.

Predloženi sustav treba sadržavati:

1. Odabrani motion capture pristup
2. Način prikupljanja podataka
3. Mogućnost integracije s drugim senzorima
4. Potencijalnu rehabilitacijsku ili robotsku primjenu
5. Prednosti i ograničenja sustava

Seminar treba sadržavati kritičku sintezu suvremenih motion capture pristupa, usporedbu tehnologija i argumentirani prijedlog vlastitog koncepta sustava.

Kontakt osoba za izradu seminara: Tara Knežević

Virtualna i proširena stvarnost u rehabilitacijskoj robotici

Tip zadatka: Teorijski seminar s naglaskom na pregled literature, analizu postojećih sustava i kritičku usporedbu primjene virtualne i proširene stvarnosti u rehabilitaciji i rehabilitacijskoj robotici.

Maksimalni broj odabira: 2

Kontekst i motivacija

Virtualna stvarnost (VR) i proširena stvarnost (AR) posljednjih godina postaju važan dio suvremenih rehabilitacijskih sustava. Integracija virtualnih okruženja s rehabilitacijskom robotikom omogućuje razvoj interaktivnih terapijskih sustava koji korisniku pružaju vizualnu povratnu informaciju, povećavaju motivaciju i omogućuju izvođenje rehabilitacijskih zadataka u kontroliranom i prilagodljivom okruženju.

VR i AR tehnologije koriste se u rehabilitaciji motoričkih funkcija, neurorehabilitaciji, rehabilitaciji nakon moždanog udara, rehabilitaciji gornjih i donjih ekstremiteta te u sustavima fizičke interakcije čovjeka i robota. Posebno se istražuje utjecaj immersive okruženja, gamification pristupa i virtualnog feedbacka na angažman korisnika, motoričko učenje i kvalitetu rehabilitacije.

Jedan od glavnih izazova je razvoj sustava koji omogućuju prirodnu interakciju korisnika s virtualnim okruženjem uz istovremeno održavanje sigurnosti, niske latencije i visoke razine personalizacije terapije.

Cilj seminara je istražiti i kritički analizirati primjenu virtualne i proširene stvarnosti u rehabilitaciji i rehabilitacijskoj robotici, s naglaskom na interakciju korisnika, motivaciju, personalizaciju terapije i integraciju s robotskim sustavima.

Varijanta A – Osnovna razina / Maksimalna ocjena: dobar (3)

Potrebno je izraditi pregled osnovnih principa virtualne i proširene stvarnosti te njihove primjene u rehabilitaciji.

Potrebno je obraditi:

1. Osnovne koncepte:
 - a. Virtualna stvarnost (VR)
 - b. Proširena stvarnost (AR)
 - c. Mixed reality (MR)
 - d. Immersive environments
2. Osnovne komponente VR/AR sustava:
 - a. Head-mounted display uređaji
 - b. Motion tracking
 - c. Kontroleri i senzori
 - d. Vizualni i auditivni feedback
3. Osnovne primjene VR/AR sustava u:
 - a. Rehabilitaciji
 - b. Neurorehabilitaciji
 - c. Rehabilitacijskoj robotici
 - d. Analizi pokreta
4. Koncept gamificationa i motivacije korisnika
5. Osnovne prednosti i ograničenja VR rehabilitacijskih sustava

Potrebno je pronaći i opisati relevantne znanstvene radove te objasniti zašto virtualna okruženja mogu poboljšati rehabilitacijski proces.

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz sve zahtjeve iz varijante A, potrebno je detaljnije analizirati postojeće rehabilitacijske sustave koji koriste VR/AR tehnologije.

Potrebno je dodatno obraditi:

1. Integraciju VR/AR sustava s:
 - a. Rehabilitacijskim robotima
 - b. Motion capture sustavima
 - c. EMG senzorima
 - d. Force sensing sustavima
2. Usporedbu:
 - a. VR i AR pristupa
 - b. Immersive i non-immersive sustava
 - c. Gaming i kliničkih rehabilitacijskih pristupa
3. Utjecaj virtualnih okruženja na:
 - a. Motivaciju korisnika
 - b. Motoričko učenje
 - c. Angažman korisnika
 - d. Kvalitetu izvođenja pokreta
4. Pregled najmanje 3 rehabilitacijska ili robotska sustava iz literature

Za svaki sustav potrebno je prikazati:

1. Korištenu VR/AR tehnologiju
2. Tip senzora
3. Način interakcije korisnika
4. Rehabilitacijsku primjenu
5. Prednosti i ograničenja sustava
6. Pregled dostupnih eksperimentalnih rezultata i kliničkih evaluacija iz literature

Seminar treba pokazati razumijevanje različitih VR/AR pristupa i njihove primjene u rehabilitacijskim sustavima.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz sve zahtjeve iz varijanti A i B, potrebno je napraviti dubinsku kritičku analizu suvremenih immersive rehabilitacijskih sustava.

Potrebno je dodatno obraditi:

1. Napredne pristupe:
 - a. Adaptive VR rehabilitation
 - b. AI-driven rehabilitation
 - c. Digital humans
 - d. Virtual avatars
 - e. Personalized rehabilitation
2. Multimodalne pristupe:
 - a. VR + motion capture
 - b. VR + EMG
 - c. VR + rehabilitation robotics
 - d. VR + haptic feedback
3. Problem user experiencea:
 - a. Embodiment
 - b. Presence
 - c. Cybersickness
 - d. Cognitive load
 - e. User acceptance
4. Real-time izazove:
 - a. Latencija

- b. Sinkronizacija podataka
 - c. Stabilnost sustava
 - d. Sigurnost fizičke interakcije
5. Buduće trendove:
- a. Metaverse rehabilitacija
 - b. Tele-rehabilitation
 - c. AI personalizacija terapije
 - d. Digital twins
 - e. Wearable immersive systems
6. Kritičku analizu učinkovitosti VR/AR sustava u usporedbi s konvencionalnim rehabilitacijskim pristupima

Potrebno je kritički usporediti - suvremene pristupe iz literature i predložiti mogući koncept VR/AR rehabilitacijskog sustava.

Predloženi sustav treba sadržavati:

1. VR/AR platformu
2. Način interakcije korisnika
3. Senzorski sustav
4. Tip rehabilitacijskog zadatka
5. Način povratne informacije korisniku
6. Potencijalnu integraciju s robotskim sustavom
7. Prednosti i ograničenja sustava

Seminar treba sadržavati kritičku sintezu suvremenih VR/AR rehabilitacijskih pristupa i argumentirani prijedlog vlastitog koncepta sustava.

Kontakt osoba za izradu seminara: Tara Knežević

Razvoj AI modela u medicinskom oslikavanju: javni slikovni skupovi podataka, anotacije i sintetski medicinski podaci

Tip zadatka: Teorijski seminar s mogućom praktičnom analizom javno dostupnog medicinskog slikovnog skupa podataka, alata za anotaciju ili koncepta sintetskog dataseta.

Maksimalni broj odabira: 2

Kontekst i motivacija

Razvoj AI modela u medicinskom oslikavanju ovisi o kvaliteti dostupnih slikovnih podataka, vrsti anotacija i reprezentativnosti pacijenata, uređaja i protokola snimanja. Medicinski datasetovi mogu uključivati CT, MR, ultrazvuk, RTG, endoskopske slike, histopatološke slike i 3D površinske podatke, a anotacije mogu biti izvedene na razini slike, regije, piksela, voksel, landmarka ili vremenske sekvence.

Cilj seminara je istražiti postojeće javne medicinske slikovne datasetove, analizirati kakve anotacije omogućuju treniranje AI modela i procijeniti ulogu sintetskih podataka te simulacijskih okruženja u razvoju rješenja za medicinsku robotiku.

Obavezni elementi seminara

Potrebno je obraditi:

- osnovne vrste medicinskih slikovnih podataka: CT, MR, ultrazvuk, RTG/fluoroskopija, endoskopija, histopatologija ili 3D površinski podaci
- vrste AI zadataka: klasifikacija, detekcija, segmentacija, landmark detekcija, praćenje i registracija
- vrste anotacija: image-level label, bounding box, segmentacijska maska, 3D/volumetrijska anotacija, anatomske landmark
- najmanje 5 javno dostupnih medicinskih datasetova
- kvalitetu anotacija i ograničenja datasetova
- aktualna znanstvena istraživanja u području medicinskih datasetova, AI modela i sintetskih podataka
- potencijalno dostupna komercijalna i otvorena rješenja za anotaciju, upravljanje datasetovima i razvoj AI modela
- povezanost datasetova s medicinskom robotikom, primjerice za robotski ultrazvuk, navigaciju, registraciju pacijenta, lokalizaciju instrumenata ili segmentaciju anatomske strukture

Varijanta A – Osnovna razina / Maksimalna ocjena: dobar (3)

Student izrađuje pregled javno dostupnih medicinskih slikovnih datasetova i objašnjava za koje AI zadatke se mogu koristiti. Potrebno je prikazati najmanje 5 datasetova te za svaki navesti modalitet, anatomske regije, vrstu anotacije, moguću primjenu i glavna ograničenja. Posebno treba objasniti zašto je medicinska anotacija zahtjevnija od anotacije u općim računalnovizijskim zadacima.

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz zahtjeve iz varijante A, student izrađuje usporednu tehničku analizu najmanje 8 datasetova i najmanje 2 alata ili platforme za anotaciju i upravljanje medicinskim podacima. Potrebno je usporediti kvalitetu anotacija, prikladnost datasetova za klasifikaciju, detekciju, segmentaciju ili registraciju te opisati metrike koje bi se koristile za evaluaciju AI modela. Student mora jasno povezati odabrane datasetove s mogućom primjenom u medicinskoj robotici.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz zahtjeve iz varijanti A i B, student izrađuje originalnu tehničku analizu, mini-implementaciju ili koncept vlastitog dataseta za medicinsku robotiku. Moguće je analizirati jedan postojeći dataset, pripremiti mali demonstracijski dataset, usporediti alate za anotaciju ili predložiti pipeline za generiranje sintetskih medicinskih podataka. Rad mora sadržavati evaluaciju predloženog pristupa, kritičku raspravu o ograničenjima i prijedlog poboljšanja.

Očekivani rezultati rada

Seminar treba dati sažet, tehnički utemeljen pregled dostupnih medicinskih datasetova, vrsta anotacija i njihove primjene u razvoju AI modela. Očekuje se usporedna tablica datasetova, pregled relevantnih znanstvenih istraživanja, pregled dostupnih alata ili komercijalnih rješenja te jasna procjena njihove primjenjivosti u medicinskoj robotici.

Kontakt osoba za izradu seminara: Filip Šuligoj, filip.suligoj@fsb.hr

Robotizirana kirurgija kralježnice: integracija medicinskog oslikavanja, senzora, navigacije i robotskih transformacija

Tip zadatka: Teorijski seminar s tehničkom analizom robotskih sustava za kirurgiju kralježnice, s naglaskom na senzore, navigaciju, medicinsko oslikavanje i transformacijski lanac između pacijenta, slike, senzora, robota i kirurškog alata.

Maksimalni broj odabira: 2

Kontekst i motivacija

Robotizirana kirurgija kralježnice razvija se kao područje koje povezuje medicinsko oslikavanje, kiruršku navigaciju, optičko ili elektromagnetsko praćenje, robotsku manipulaciju i precizno pozicioniranje instrumenata. Kod takvih zahvata ključno je pouzdano odrediti prostorni odnos između preoperativnih ili intraoperativnih slika, anatomije pacijenta, lokalizacijskog sustava, robotske baze i kirurškog alata.

Cilj seminara je istražiti suvremene robotske sustave za kirurgiju kralježnice, analizirati ulogu senzora i navigacije te objasniti kako se transformacije između koordinatnih sustava koriste za sigurno i precizno vođenje kirurškog instrumenta.

Obavezni elementi seminara

Potrebno je obraditi:

- osnovne medicinske zahtjeve i specifičnosti zahvata na kralježnici
- primjenu medicinskog oslikavanja: CT, intraoperativni CT, RTG, fluoroskopija, ultrazvuk ili navigacijski sustavi
- postojeće robotske sustave za kirurgiju kralježnice i njihovu razinu autonomije
- vrste senzora u robotskoj kirurgiji kralježnice:
 - optički lokalizacijski sustavi
 - elektromagnetsko praćenje
 - intraoperativno oslikavanje
 - senzori sile/momenta
 - enkoderi i robotska kinematika
- transformacijski lanac između slike, pacijenta, senzora, robota i kirurškog alata
- osnovne pojmove registracije pacijenta i navigacije instrumenta
- aktualna znanstvena istraživanja u području robotske kirurgije kralježnice
- potencijalno dostupna komercijalna rješenja i klinički korišteni sustavi
- izvore pogreške: registracija, kalibracija, gibanje pacijenta, deformacije, pogreška robota i pogreška lokalizacijskog sustava
- sigurnosne zahtjeve i ograničenja primjene u kliničkom okruženju

Varijanta A – Osnovna razina / Maksimalna ocjena: dobar (3)

Student izrađuje pregled područja robotske kirurgije kralježnice i objašnjava osnovnu ulogu medicinskog oslikavanja, navigacije i robota u izvođenju zahvata. Potrebno je opisati najmanje 3 postojeća robotska ili navigacijska sustava te za svaki navesti osnovnu namjenu, korištene senzore, medicinski modalitet i glavna

ograničenja. Posebno treba objasniti zašto je precizna lokalizacija pacijenta važna za sigurnost zahvata na kralježnici.

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz zahtjeve iz varijante A, student izrađuje usporednu tehničku analizu najmanje 5 sustava ili istraživačkih rješenja za robotsku kirurgiju kralježnice. Potrebno je usporediti način lokalizacije pacijenta, korištene senzore, vrstu medicinskog oslikavanja, razinu integracije s robotom, način registracije i izvore pogreške. Student mora prikazati i objasniti osnovni transformacijski lanac, primjerice CT/slika – pacijent – lokalizacijski sustav – robot – alat.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz zahtjeve iz varijanti A i B, student izrađuje originalnu tehničku analizu transformacijskog lanca ili predlaže koncept robotskog sustava za precizno vođenje instrumenta u kirurgiji kralježnice. Moguće je analizirati propagaciju pogreške kroz koordinatne transformacije, usporediti eye-to-hand i eye-in-hand konfiguracije senzora ili predložiti arhitekturu sustava koji kombinira intraoperativno oslikavanje, navigaciju i robotsko pozicioniranje. Rad mora sadržavati evaluaciju predloženog pristupa, kritičku raspravu o ograničenjima i prijedlog poboljšanja.

Očekivani rezultati rada

Seminar treba dati tehnički utemeljen pregled robotske kirurgije kralježnice, s jasnim razlikovanjem medicinskog oslikavanja, navigacije, registracije, lokalizacije pacijenta i robotskog izvršavanja zahvata. Očekuje se usporedna tablica postojećih sustava, pregled aktualnih znanstvenih istraživanja, pregled dostupnih komercijalnih rješenja te shematski prikaz transformacija između slike, pacijenta, senzora, robota i alata.

Kontakt osoba za izradu seminara : Filip Šuligoj

Magnetski lokalizirani i aktuirani medicinski instrumenti za minimalno invazivne robotske zahvate

Tip zadatka: Teorijski seminar s tehničkom analizom magnetski lokaliziranih i/ili magnetski aktuiranih medicinskih instrumenata, s naglaskom na primjenu u minimalno invazivnoj kirurgiji, intervencijskoj radiologiji, endoskopiji, kateterizaciji i neurokirurgiji.

Maksimalni broj odabira: 2

Kontekst i motivacija

Magnetski lokalizirani i aktuirani medicinski instrumenti omogućuju navođenje i praćenje malih, fleksibilnih ili teško dostupnih alata unutar ljudskog tijela, gdje klasična optička lokalizacija često nije moguća zbog nedostatka vidljivosti. Takvi sustavi mogu uključivati magnetski praćene katetere, igle, endoskopske instrumente, fleksibilne kirurške alate, mikrorobote ili instrumente upravljane vanjskim elektromagnetskim poljem.

Cilj seminara je istražiti principe magnetske lokalizacije i magnetske aktuacije u medicinskoj robotici, analizirati postojeća istraživačka i komercijalna rješenja te objasniti kako se takvi instrumenti mogu koristiti za precizne, sigurnije i manje invazivne medicinske zahvate.

Obavezni elementi seminara

Potrebno je obraditi:

- osnovne principe magnetske lokalizacije medicinskih instrumenata
- osnovne principe magnetske aktuacije i daljinskog upravljanja instrumentima
- razliku između magnetske lokalizacije, magnetske aktuacije i kombiniranih sustava
- vrste medicinskih instrumenata:
 - magnetski praćeni kateteri
 - fleksibilni kirurški alati
 - magnetski upravljani endoskopski instrumenti
 - mikroroboti i mikroagenti
 - instrumenti za neurokirurgiju ili vaskularne zahvate
- konfiguracije sustava:
 - permanentni magneti
 - elektromagnetski aktuatori
 - hibridni magnetski sustavi
 - integracija s robotskom rukom
 - integracija s medicinskim oslikavanjem
- metode lokalizacije:
 - elektromagnetsko praćenje
 - lokalizacija pomoću medicinskog oslikavanja
 - ultrazvučno, fluoroskopsko, MR ili optičko praćenje

- fuzija senzora
- aktualna znanstvena istraživanja u području magnetski upravljanih medicinskih instrumenata
- potencijalno dostupna komercijalna rješenja i klinički korišteni sustavi
- sigurnosne izazove:
 - ograničenje magnetskih sila i momenata
 - zagrijavanje tkiva ili instrumenata
 - kompatibilnost s MR-om
 - utjecaj metalnih objekata
 - pouzdanost lokalizacije
 - kontrola gibanja u deformabilnom tkivu

Varijanta A – Osnovna razina / Maksimalna ocjena: dobar (3)

Student izrađuje pregled magnetske lokalizacije i magnetske aktuacije medicinskih instrumenata te objašnjava osnovne principe rada takvih sustava. Potrebno je opisati najmanje 3 primjera primjene, primjerice kateterizaciju, endoskopiju, mikrorobotiku ili neurokirurgiju. Posebno treba objasniti zašto su magnetski pristupi korisni u situacijama gdje optičko praćenje i rigidni instrumenti imaju ograničenja.

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz zahtjeve iz varijante A, student izrađuje usporednu tehničku analizu najmanje 5 istraživačkih ili komercijalnih rješenja. Potrebno je usporediti vrstu instrumenta, način lokalizacije, način aktuacije, korištene senzore, medicinsko oslikavanje, razinu autonomije i glavna ograničenja sustava. Student mora jasno razlikovati sustave koji samo lokaliziraju instrument od sustava koji instrument aktivno magnetski pomiču ili usmjeravaju.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz zahtjeve iz varijanti A i B, student izrađuje originalnu tehničku analizu ili predlaže koncept magnetski lokaliziranog i aktuiranog instrumenta za odabrani medicinski zahvat. Moguće je analizirati transformacijski lanac lokalizacije, usporediti magnetsko i optičko praćenje, predložiti sustav za magnetski upravljani kateter ili fleksibilni neurokirurški alat, ili analizirati osnovne zahtjeve za zatvorenu petlju upravljanja. Rad mora sadržavati evaluaciju predloženog koncepta, kritičku raspravu o ograničenjima i prijedlog poboljšanja.

Očekivani rezultati rada

Seminar treba dati jasan pregled magnetske lokalizacije i aktuacije u medicinskoj robotici te pokazati razumijevanje razlike između senzorskog praćenja instrumenta i stvarnog magnetskog upravljanja njegovim gibanjem. Očekuje se usporedna tablica istraživačkih i komercijalnih rješenja, pregled aktualnih znanstvenih istraživanja, prikaz osnovnih konfiguracija sustava te analiza sigurnosnih i tehničkih ograničenja primjene u medicini.

Kontakt osoba za izradu seminara : Filip Šuligoj

Teleoperirana medicinska robotika: udaljena dijagnostika, robotska kirurgija i sigurnost prijenosa podataka

Tip zadatka: Teorijski seminar s tehničkom analizom teleoperiranih medicinskih robotskih sustava, s naglaskom na konfiguracije sustava, prijenos podataka, kašnjenje, sigurnost komunikacije i postojeća istraživačka ili komercijalna rješenja.

Maksimalni broj odabira: 2

Kontekst i motivacija

Teleoperirana medicinska robotika omogućuje da liječnik ili operator upravlja dijagnostičkim ili kirurškim robotskim sustavom s udaljene lokacije, dok se robot, pacijent i medicinsko osoblje nalaze u kliničkom okruženju. Takav pristup može povećati dostupnost specijalizirane medicinske skrbi, omogućiti udaljenu dijagnostiku, podržati rad u izoliranim ili teško dostupnim područjima te smanjiti potrebu za fizičkom prisutnošću stručnjaka.

Cilj seminara je istražiti koncepte teleoperirane dijagnostike i kirurgije, analizirati arhitekture sustava i komunikacijske zahtjeve te usporediti postojeća istraživačka i komercijalna rješenja u području udaljenog robotskog pregleda ili zahvata.

Obavezni elementi seminara

Potrebno je obraditi:

- osnovne principe teleoperacije u medicinskoj robotici
- razliku između udaljene dijagnostike, teleoperirane kirurgije i djelomično autonomnih robotskih zahvata
- osnovne konfiguracije sustava:
 - master–slave robotska konfiguracija
 - lokalni robot i udaljena upravljačka konzola
 - udaljeni liječnik i lokalni medicinski tim
 - teleoperacija s lokalnom sigurnosnom autonomijom
 - shared autonomy pristupi
- vrste podataka koji se prenose:
 - video
 - medicinske slike
 - robotske naredbe
 - položaj i brzina robota
 - sila i haptika
 - zvuk i komunikacija s lokalnim timom
 - sigurnosni status sustava
- komunikacijske zahtjeve:
 - propusnost
 - latencija

- jitter
- pouzdanost veze
- sinkronizacija podataka
- cyber sigurnost
- zaštita medicinskih podataka
- aktualna znanstvena istraživanja u području teleoperirane dijagnostike i kirurgije
- potencijalno dostupna komercijalna rješenja i klinički korišteni sustavi
- sigurnosne mehanizme:
 - ograničenje brzine i sile
 - lokalni nadzor robota
 - hitno zaustavljanje
 - detekcija prekida veze
 - fallback način rada
 - lokalna potvrda kritičnih radnji
- ograničenja:
 - kašnjenje upravljanja
 - gubitak haptike
 - promjenjiva kvaliteta mreže
 - odgovornost i regulativa
 - potreba za lokalnim medicinskim osobljem

Varijanta A – Osnovna razina / Maksimalna ocjena: dobar (3)

Student izrađuje pregled teleoperirane medicinske robotike i objašnjava osnovnu razliku između udaljene dijagnostike, teleoperirane kirurgije i djelomično autonomnih sustava. Potrebno je opisati najmanje 3 postojeća istraživačka ili komercijalna sustava te za svaki navesti medicinsku primjenu, osnovnu konfiguraciju, vrstu podataka koji se prenose i glavna ograničenja. Posebno treba objasniti zašto su latencija, sigurnost veze i lokalni nadzor važni u medicinskom okruženju.

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz zahtjeve iz varijante A, student izrađuje usporednu tehničku analizu najmanje 5 teleoperiranih medicinskih robotskih sustava ili istraživačkih rješenja. Potrebno je usporediti arhitekturu sustava, način upravljanja, vrstu povratne informacije, komunikacijski protokol ili mrežnu infrastrukturu, razinu autonomije i sigurnosne mehanizme. Student mora prikazati kako latencija, jitter i gubitak podataka mogu utjecati na stabilnost, preciznost i sigurnost teleoperiranog zahvata.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz zahtjeve iz varijanti A i B, student izrađuje originalnu tehničku analizu ili predlaže koncept teleoperiranog medicinskog robotskog sustava za odabranu dijagnostičku ili kiruršku primjenu. Moguće je analizirati latenciju u prijenosu naredbi i slike, predložiti komunikacijsku arhitekturu, usporediti TCP/UDP ili druge protokole, analizirati ulogu haptike ili predložiti shared autonomy sustav s lokalnim sigurnosnim nadzorom. Rad mora sadržavati evaluaciju predloženog koncepta, kritičku raspravu o ograničenjima i prijedlog poboljšanja.

Očekivani rezultati rada

Seminar treba dati tehnički utemeljen pregled teleoperirane medicinske robotike, s jasnim razlikovanjem udaljene dijagnostike, kirurške teleoperacije i djelomične autonomije. Očekuje se usporedna tablica postojećih istraživačkih i komercijalnih sustava, pregled aktualnih znanstvenih istraživanja, prikaz konfiguracije teleoperiranog sustava te analiza komunikacijskih, sigurnosnih i regulatornih ograničenja.

Kontakt osoba za izradu seminara : Filip Šuligoj

Multimodalna registracija pacijenta za robotski vođene zahvate: CT, MR, ultrazvuk, 3D površina i koordinatni sustavi robota

Tip zadatka: Teorijski seminar s tehničkom analizom metoda registracije pacijenta u medicinskoj robotici, s naglaskom na povezivanje preoperativnih i intraoperativnih slika, 3D površinskih podataka, senzora i robotskog koordinatnog sustava.

Maksimalni broj odabira: 2

Kontekst i motivacija

U robotski vođenim medicinskim zahvatima potrebno je anatomske ciljeve definirane u slikovnom prostoru, primjerice u CT, MR ili ultrazvučnim slikama, pouzdano povezati s fizičkim položajem pacijenta i robota u operacijskoj dvorani. Multimodalna registracija omogućuje povezivanje različitih izvora podataka, kao što su preoperativni volumeni, intraoperativne slike, 3D površina pacijenta, lokalizacijski sustavi i robotska kinematika.

Cilj seminara je istražiti metode multimodalne registracije pacijenta, objasniti razliku između rigidne, deformabilne i površinske registracije te analizirati kako se transformacijski lanac koristi za navigaciju i sigurno izvođenje robotski vođenih zahvata.

Obavezni elementi seminara

Potrebno je obraditi:

- osnovni pojam registracije pacijenta u medicinskoj robotici
- razliku između registracije u slikovnom prostoru i lokalizacije u fizičkom prostoru
- medicinske modalitete koji se koriste za registraciju:
 - CT
 - MR
 - ultrazvuk
 - fluoroskopija
 - optičko 3D snimanje površine
 - intraoperativni point cloud podaci
- vrste registracije:
 - rigidna registracija
 - deformabilna registracija
 - površinska registracija
 - landmark-based registracija
 - intensity-based registracija
 - feature-based registracija
 - point cloud registracija
- ulogu senzora i lokalizacijskih sustava:
 - optički tracking sustavi

- elektromagnetsko praćenje
- stereo kamere
- RGB-D kamere
- ultrazvučne sonde
- robotska kinematika
- transformacijski lanac između slike, pacijenta, senzora, robota i alata
- metode evaluacije registracije:
 - fiducial registration error
 - target registration error
 - surface registration error
 - Dice coefficient za segmentacijsko preklapanje
 - landmark error
 - pogreška vrha alata
- aktualna znanstvena istraživanja u području multimodalne registracije
- potencijalno dostupna komercijalna i otvorena rješenja za registraciju, navigaciju i medicinsku robotiku
- izvore pogreške:
 - pogreška segmentacije
 - pogreška lokalizacije landmarka
 - pogreška kalibracije senzora
 - gibanje pacijenta
 - deformacija mekog tkiva
 - razlika između preoperativne i intraoperativne anatomije
 - pogreška robotske kinematike

Varijanta A – Osnovna razina / Maksimalna ocjena: dobar (3)

Student izrađuje pregled metoda registracije pacijenta i objašnjava osnovnu razliku između rigidne, deformabilne, površinske i landmark-based registracije. Potrebno je opisati najmanje 3 primjene multimodalne registracije u medicinskoj robotici, primjerice neurokirurgiju, kirurgiju kralježnice, robotski ultrazvuk ili robotski vođenu biopsiju. Posebno treba objasniti zašto pogreška registracije izravno utječe na sigurnost i točnost robotski vođenog zahvata.

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz zahtjeve iz varijante A, student izrađuje usporednu tehničku analizu najmanje 5 metoda, sustava ili istraživačkih rješenja za multimodalnu registraciju pacijenta. Potrebno je usporediti korištene modalitete, vrstu registracije, lokalizacijski sustav, način evaluacije, točnost i glavna ograničenja. Student mora prikazati i objasniti transformacijski lanac kojim se ciljana anatomska točka iz CT/MR/UZV slike transformira u koordinatni sustav robota.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz zahtjeve iz varijanti A i B, student izrađuje originalnu tehničku analizu ili predlaže koncept registracijskog sustava za odabrani robotski medicinski zahvat. Moguće je analizirati propagaciju pogreške kroz transformacijski lanac, usporediti landmark-based i surface-based registraciju, predložiti pipeline za CT/MR/3D površinsku registraciju ili analizirati primjenu ultrazvuka kao intraoperativnog modaliteta za ažuriranje registracije. Rad mora sadržavati evaluaciju predloženog pristupa, kritičku raspravu o ograničenjima i prijedlog poboljšanja.

Očekivani rezultati rada

Seminar treba dati tehnički utemeljen pregled multimodalne registracije pacijenta u medicinskoj robotici, s jasnim razlikovanjem slikovnog prostora, fizičkog prostora, senzorskog prostora i koordinatnog sustava robota. Očekuje se usporedna tablica metoda ili sustava, pregled aktualnih znanstvenih istraživanja, pregled dostupnih komercijalnih ili otvorenih rješenja te shematski prikaz transformacija između slike, pacijenta, senzora, robota i alata.

Kontakt osoba za izradu seminara : Filip Šuligoj

Mekani roboti u medicini i minimalno invazivnoj kirurgiji

Tip zadatka: Teorijski seminar s tehničkom analizom mekanih robotskih sustava u medicini, uz moguću usporedbu s klasičnim krutim robotima, pregled primjena u minimalno invazivnoj kirurgiji, rehabilitaciji, dijagnostici ili asistivnim medicinskim uređajima.

Maksimalni broj odabira: 2

Kontekst i motivacija

Mekani roboti, odnosno **soft robots**, predstavljaju važan razvojni smjer u medicinskoj robotici jer omogućuju sigurniju i prilagodljiviju interakciju s ljudskim tijelom u odnosu na klasične krute robotske sustave. Konvencionalni roboti najčešće su izrađeni od krutih članaka i zglobova te zahtijevaju precizno upravljanje, sigurnosne mehanizme i pažljivo ograničavanje sila pri kontaktu s pacijentom.

Za razliku od njih, mekani roboti koriste fleksibilne, elastične i deformabilne materijale, zbog čega se mogu prirodnije prilagoditi anatomskim strukturama, tkivu i promjenjivim uvjetima u medicinskom okruženju. Njihova intrinzična mehanička podatljivost može smanjiti rizik ozljede, pojednostaviti kontakt s pacijentom i omogućiti razvoj novih medicinskih proizvoda za terapiju, dijagnostiku, rehabilitaciju i minimalno invazivnu kirurgiju.

Cilj seminara je objasniti osnovne principe mekanih robota, analizirati njihove prednosti i ograničenja u medicinskoj primjeni te kritički procijeniti njihov potencijal u minimalno invazivnoj kirurgiji i drugim područjima medicinske robotike.

Obavezni elementi seminara

Potrebno je obraditi (**Varijanta A – Osnovna razina**):

- pojam mekanih robota i razliku u odnosu na krute robote
- osnovne vrste mekanih materijala i struktura
- pneumatske, hidrauličke, kableske, magnetske i druge načine aktivacije
- senzore i metode mjerenja deformacije, sile i kontakta
- upravljanje mekanim robotima i izazove modeliranja deformabilnih struktura
- sigurnost interakcije s pacijentom
- primjene u rehabilitaciji, asistivnim uređajima, dijagnostici i kirurgiji
- glavne prednosti, ograničenja i izazove kliničke primjene

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz zahtjeve iz varijante A, potrebno je izraditi tehničku usporedbu najmanje 3 primjene mekanih robota u medicini, primjerice u rehabilitacijskim rukavicama, mekanim endoskopskim instrumentima, kateterima, kirurškim manipulatorima ili asistivnim uređajima. Potrebno je analizirati strukturu, aktivaciju, senzore, upravljanje, sigurnost i ograničenja.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz zahtjeve iz varijanti A i B, potrebno je izraditi originalnu tehničku analizu, evaluacijski okvir ili koncept mekanog robotskog sustava za medicinsku primjenu. Moguće je predložiti mekani kirurški instrument, mekani robotski endoskop, rehabilitacijski egzoskelet, hvataljku za osjetljivo tkivo ili sustav za sigurnu fizičku interakciju s pacijentom. Konkretni rezultat rada je vlastiti koncept rješenja, blok-dijagram, opis aktivacije i senzora, kriteriji evaluacije, analiza sigurnosnih rizika i kritička procjena izvedivosti.

Kontakt osoba za izradu seminara : Marko Švaco

Robotizirana laboratorijska dijagnostika

Tip zadatka: Teorijski seminar s obaveznom tehničkom analizom robotiziranih i automatiziranih laboratorijskih sustava, uz moguću usporedbu komercijalnih rješenja, tijeka obrade uzorka, robotske manipulacije, integracije s laboratorijskim informacijskim sustavima i utjecaja na učinkovitost dijagnostike.

Maksimalni broj odabira: 2

Kontekst i motivacija

Robotizirana laboratorijska dijagnostika pripada području medicinske robotike u širem smislu jer uključuje sustave koji automatizirano manipuliraju biološkim uzorcima, provode njihovu pripremu, sortiranje, transport, analizu, pohranu i povezivanje s laboratorijskim informacijskim sustavima. Za razliku od kirurških robota, laboratorijski robotski sustavi ne djeluju izravno na pacijenta, ali imaju važnu ulogu u brzini, točnosti i sigurnosti dijagnostičkog procesa.

Važno je razlikovati običnu laboratorijsku automatizaciju od robotike. Nije svaki automatski analizator robot, ali sustavi s programabilnim gibanjem, robotskom manipulacijom uzorcima, senzorima, računalnim nadzorom, autonomnim radom i koordinacijom više modula mogu se smatrati dijelom medicinske robotike. Cilj seminara je analizirati takve sustave i kritički procijeniti njihov doprinos suvremenoj laboratorijskoj medicini.

Obavezni elementi seminara

Potrebno je obraditi (**Varijanta A – Osnovna razina**):

- pojam robotizirane laboratorijske dijagnostike
- razliku između laboratorijske automatizacije i laboratorijske robotike
- tipičan tijek obrade uzorka u kliničkom laboratoriju
- robotsko zaprimanje, identifikaciju, sortiranje i transport uzoraka
- uklanjanje čepova, centrifugiranje, pipetiranje i alikvotiranje
- automatizirane analizatore i integrirane laboratorijske trake
- povezivanje s laboratorijskim informacijskim sustavima
- prednosti, ograničenja, sigurnost, sljedivost i validaciju sustava

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz zahtjeve iz varijante A, potrebno je izraditi tehničku usporedbu najmanje 3 vrste laboratorijskih robotskih sustava, primjerice predanalitičkih modula, robotskih sustava za pipetiranje, sustava za molekularnu dijagnostiku ili automatiziranih biobanki. Potrebno je analizirati manipulaciju uzorcima, senzore, sljedivost, integraciju s informacijskim sustavom i ograničenja primjene.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz zahtjeve iz varijanti A i B, potrebno je izraditi originalnu tehničku analizu, evaluacijski okvir ili koncept robotiziranog laboratorijskog sustava. Moguće je predložiti koncept automatiziranog toka krvnog uzorka, robotskog pipetiranja, transporta uzoraka, integracije sustava za smanjenje pogrešaka i kontaminacije. Konkretni rezultat rada je vlastiti koncept rješenja, blok-dijagram, kriteriji evaluacije, analiza rizika i kritička procjena izvedivosti.

Kontakt osoba za izradu seminara : Marko Švaco

Bolnička automatizacija i robotski sustavi u zdravstvenim ustanovama

Tip zadatka: Teorijski seminar s obaveznom tehničkom usporedbom robotskih i automatiziranih sustava koji se koriste u bolničkom okruženju, uz moguću analizu autonomne navigacije, logističkih procesa, dezinfekcije, distribucije lijekova, prijenosa uzoraka ili integracije s bolničkim informacijskim sustavima.

Maksimalni broj odabira: 2

Kontekst i motivacija

Bolnička automatizacija može se smatrati dijelom medicinske robotike u širem smislu. Iako se medicinska robotika često povezuje s kirurškim robotima, rehabilitacijskim robotima, robotskim sustavima za biopsiju, radioterapiju ili asistivnu skrb, suvremeno područje uključuje i robotske sustave koji ne sudjeluju izravno u terapijskom postupku, ali bitno unaprjeđuju rad zdravstvenih ustanova.

Roboti za bolničku logistiku, dezinfekciju, automatiziranu distribuciju lijekova, prijenos uzoraka i podršku bolničkom osoblju pridonose sigurnosti pacijenata, učinkovitosti procesa, smanjenju rizika od infekcija i rasterećenju medicinskog osoblja.

Cilj seminara je analizirati primjenu robotskih sustava i automatiziranih tehnologija u bolničkom okruženju te kritički procijeniti njihove tehničke mogućnosti, ograničenja i doprinos zdravstvenom sustavu.

Obavezni elementi seminara

Potrebno je obraditi (**Varijanta A – Osnovna razina**):

- pojam bolničke automatizacije u kontekstu medicinske robotike
- razloge uvođenja automatizacije u bolnicama
- autonomne mobilne robote za bolničku logistiku
- robote za dezinfekciju prostora
- sustave za automatiziranu distribuciju lijekova
- robotski ili automatizirani prijenos uzoraka, opreme i potrošnog materijala
- senzore, navigaciju, lokalizaciju i sigurnosne funkcije mobilnih robota
- integraciju s bolničkim informacijskim sustavima
- utjecaj na sigurnost pacijenata, osoblja i organizaciju rada

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz zahtjeve iz varijante A, potrebno je izraditi detaljniju tehničku usporedbu najmanje 3 vrste sustava, primjerice autonomnih mobilnih robota, robota za dezinfekciju i automatiziranih sustava za distribuciju lijekova. Potrebno je analizirati senzore, navigaciju, sigurnosne mehanizme, način integracije u bolnički proces, prednosti, ograničenja i moguće rizike.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz zahtjeve iz varijanti A i B, potrebno je izraditi originalnu tehničku analizu, evaluacijski okvir ili koncept automatiziranog bolničkog sustava. Moguće je predložiti koncept robotske dostave lijekova, optimizaciju logističkih ruta, sustav za koordinaciju više mobilnih robota, protokol UV dezinfekcije ili model integracije robota s bolničkim informacijskim sustavom. Konkretni rezultat rada je vlastiti koncept rješenja, blok-dijagram sustava, kriteriji evaluacije, analiza sigurnosnih rizika i kritička procjena izvedivosti.

Kontakt osoba za izradu seminara : Marko Švaco

Da Vinci i Senhance Surgical System: teleoperirani kirurški robotski sustavi u laparoskopskoj kirurgiji

Tip zadatka: Teorijski seminar s obaveznom tehničkom usporedbom dvaju komercijalnih teleoperiranih kirurških robotskih sustava, uz moguću analizu arhitekture, upravljanja, ergonomije, instrumenata, haptičke povratne veze ili primjene u minimalno invazivnoj kirurgiji.

Maksimalni broj odabira: 2

Kontekst i motivacija

Robotski kirurški sustavi danas se najčešće primjenjuju u minimalno invazivnoj laparoskopskoj kirurgiji, gdje omogućuju izvođenje zahvata kroz male rezove, uz poboljšanu preciznost, stabilniju manipulaciju instrumentima, bolju vizualizaciju operacijskog polja i povoljniju ergonomiju rada kirurga. Takvi sustavi nisu autonomni roboti, nego teleoperirani sustavi u kojima kirurg upravlja instrumentima putem konzole, dok robotski sustav prenosi, filtrira i skalira pokrete na instrumente unutar tijela pacijenta.

Najpoznatiji sustav ove vrste je **da Vinci Surgical System**, široko korišten u robotski asistiranoj laparoskopiji. Jedan od alternativnih sustava je **Senhance Surgical System**, koji se temelji na laparoskopskoj kirurškoj praksi, ali uvodi robotsko upravljanje, otvorenu konzolu, haptičku povratnu vezu, upravljanje kamerom pogledom i druge napredne značajke.

Obavezni elementi seminara

Potrebno je obraditi (**Varijanta A – Osnovna razina**):

- osnovne principe minimalno invazivne laparoskopske kirurgije
- razliku između klasične i robotski asistirane laparoskopije
- pojam teleoperacije i ulogu kirurga u upravljačkoj petlji
- arhitekturu sustava: konzola, robotske ruke, instrumenti, kamera, softver i pacijent
- tehnički opis sustava da Vinci i Senhance Surgical System
- konstrukcijske, mehatroničke, upravljačke i softverske značajke
- vizualizaciju, ergonomiju, haptičku povratnu vezu i sigurnost
- primjenu sustava u laparoskopskoj kirurgiji

Varijanta B – Srednja razina / Maksimalna ocjena: vrlo dobar (4)

Uz zahtjeve iz varijante A, potrebno je izraditi detaljniju tehničku usporedbu sustava. Potrebno je analizirati značajke kao što su: konstrukcija, raspored robotskih ruku, upravljanje instrumentima, vizualizacija, ergonomija, haptička povratna veza, sigurnosne funkcije i utjecaj na operacijski tijek.

Varijanta C – Napredna razina / Maksimalna ocjena: odličan (5)

Uz zahtjeve iz varijanti A i B, student izrađuje originalnu tehničku analizu, evaluacijski okvir ili koncept potencijalne nadogradnje jednog od dvaju sustava. Moguće je analizirati ograničenja haptičke povratne veze, procjenu sile na tkivo, latenciju, sigurnost, ergonomiju, troškove instrumenata ili mogućnosti integracije AI metoda. Konkretni rezultat rada je vlastiti evaluacijski okvir, koncept nadogradnje ili prijedlog eksperimentalnog protokola, uz blok-dijagram, kriterije evaluacije i kritičku procjenu izvedivosti.

Kontakt osoba za izradu seminara : Marko Švaco